Projet
Modèle hiérarchique bayésien pour l'écologie

Houssam-Eddine FIDANI

Structure du code

```
projet/
|-- data/
|   |-- aedes_albopictus_france_metropolitaine.csv
|   |-- diagnostic_hmc.csv
|   |-- echantillons_hmc.csv
|   |-- grille_hmc.csv
|   |-- prediction_annees.csv
|   |-- prediction_observations.csv
|   |-- prediction_resume.csv
|   |-- resume_posterior_annees.csv
|   |-- resume_posterior_global.csv
|   `-- table_resumee.csv
|-- scripts/
|   |-- 01_Extraction.R
|   |-- 02_Transformation.py
|   |-- 03_Description.py
|   |-- modele.py
|   |-- 05_estimation.py
|   |-- 06_diagnostique.py
|   `-- 07_prediction.py
|-- figures/
|   |-- carte_occurrences.png
|   |-- hmc_chaines.png
|   |-- hmc_prediction_annees.png
|   |-- hmc_prediction_residus.png
|   |-- hmc_tau2.png
|   |-- hmc_variabilite_annees.png
|   `-- occurrences_par_annee.png
`-- raport/
    `-- rapport.pdf
```

I - Extraction des données et pré-traitement

1. Extraction des données

Les données sont extraites depuis GBIF avec `rgbif` sous R. La requête retient :
- l'espèce *Aedes albopictus* ;
- la France métropolitaine ;
- les occurrences de présence.

Sortie obtenue :
- fichier : `aedes_albopictus_france_metropolitaine.csv` ;
- taille : 2200 lignes ;
- variables utilisées : `year`, `stateProvince`, `decimalLatitude`, `decimalLongitude`.

2. Construction de la table résumée

Chaque ligne initiale est une occurrence observée. Le pré-traitement est :
- retrait des lignes sans `stateProvince` ;
- comptage des occurrences par couple `(year, stateProvince)`.
- sortie : `table_resumee.csv`, avec 84 observations.

3. Première description des données

Premiers constats :
— le fichier brut contient des observations de 1999 à 2025 ;
— la table résumée utilisée pour le modèle couvre 13 années, de 2010 à 2025 ;
— les coordonnées couvrent bien le territoire français ;
— les régions les plus représentées sont l'Occitanie, Rhône-Alpes et Provence-Alpes-Côte d'Azur.
— les occurrences sont plus nombreuses dans le sud et le sud-est ;
— elles augmentent globalement au fil du temps.

La figure 1 décrit la répartition géographique. La figure 2 décrit l'évolution annuelle.

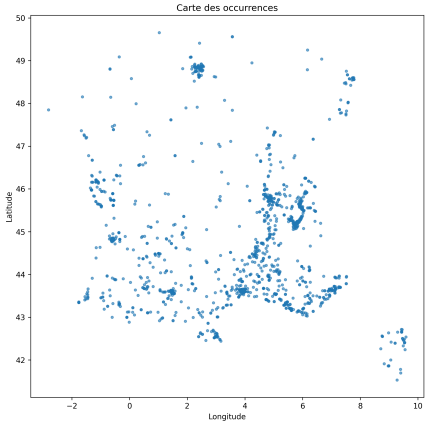


FIGURE 1 – Répartition géographique des occurrences

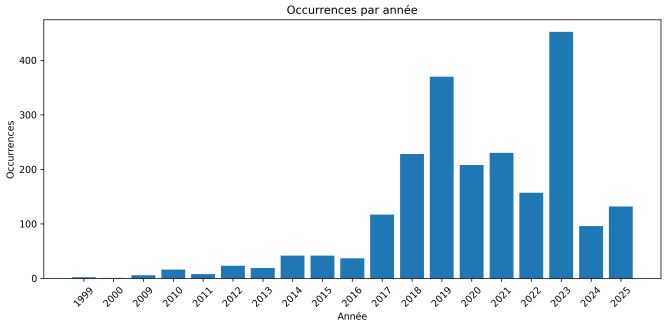


FIGURE 2 – Nombre d'occurrences par année

II - Modèle

4. Fonction de log-vraisemblance

Soit I le nombre d'années.
Soit n_i le nombre de sites observés pour l'année i.
Pour tout $i \in \{1, \dots, I\}$ et pour tout $j \in \{1, \dots, n_i\}$, on observe y_{ij}.
Le modèle est

$$Y_{ij} \mid \lambda_i \sim \mathcal{P}(\lambda_i), \qquad \log \lambda_i \mid \mu, \tau \sim \mathcal{N}(\mu, \tau^2).$$

a) Loi a priori de λ_i

Comme

$$\log \lambda_i \mid \mu, \tau \sim \mathcal{N}(\mu, \tau^2),$$

on en déduit

$$\lambda_i \mid \mu, \tau \sim \mathcal{LN}(\mu, \tau^2),$$

de densité

$$f(\lambda_i \mid \mu, \tau) = \frac{1}{\lambda_i \tau \sqrt{2\pi}} \exp\left(-\frac{(\log \lambda_i - \mu)^2}{2\tau^2}\right), \qquad \lambda_i > 0.$$

b) Vraisemblance conditionnelle de y sachant λ

Soit i, pour tout j,

$$\mathbb{P}(Y_{ij} = y_{ij} \mid \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^{y_{ij}}}{y_{ij}!}.$$

Par indépendance conditionnelle,

$$L(y \mid \lambda_1, \dots, \lambda_I) = \prod_{i=1}^{I} \prod_{j=1}^{n_i} \frac{e^{-\lambda_i} \lambda_i^{y_{ij}}}{y_{ij}!}.$$

c) Vraisemblance jointe

La densité jointe de $(y, \lambda_1, \dots, \lambda_I)$ est

$$L(\mu, \tau, \lambda_1, \dots, \lambda_I; y) = f(y, \lambda_1, \dots, \lambda_I \mid \mu, \tau) = f(y \mid \lambda_1, \dots, \lambda_I)\, f(\lambda_1, \dots, \lambda_I \mid \mu, \tau).$$

Comme les λ_i sont indépendantes conditionnellement à (μ, τ),

$$f(\lambda_1, \dots, \lambda_I \mid \mu, \tau) = \prod_{i=1}^{I} f(\lambda_i \mid \mu, \tau).$$

Donc

$$L(\mu, \tau, \lambda_1, \ldots, \lambda_I; y) = \prod_{i=1}^{I} \left[\left(\prod_{j=1}^{n_i} \frac{e^{-\lambda_i} \lambda_i^{y_{ij}}}{y_{ij}!} \right) \frac{1}{\lambda_i \tau \sqrt{2\pi}} \exp\left(-\frac{(\log \lambda_i - \mu)^2}{2\tau^2} \right) \right].$$

d) Log-vraisemblance jointe

On a

$$\ell(\mu, \tau, \lambda_1, \ldots, \lambda_I; y) = \sum_{i=1}^{I} \left[\sum_{j=1}^{n_i} (-\lambda_i + y_{ij} \log \lambda_i - \log(y_{ij}!)) - \log \lambda_i - \log \tau - \frac{1}{2} \log(2\pi) - \frac{(\log \lambda_i - \mu)^2}{2\tau^2} \right]$$

$$\Longleftrightarrow$$

$$\ell(\mu, \tau, \lambda_1, \ldots, \lambda_I; y) = \sum_{i=1}^{I} \left[-n_i \lambda_i + \left(\sum_{j=1}^{n_i} y_{ij} - 1 \right) \log \lambda_i - \frac{(\log \lambda_i - \mu)^2}{2\tau^2} \right] - I \log \tau - \frac{I}{2} \log(2\pi) - \sum_{i=1}^{I} \sum_{j=1}^{n_i} \log(y_{ij}!).$$

5. Choix des lois a priori

On complète la vraisemblance par une loi a priori sur

$$(\mu, \tau), \qquad \mu \in \mathbb{R}, \qquad \tau > 0.$$

Les hyperparamètres sont fixes. On suppose μ et τ indépendants a priori :

$$\mu \sim \mathcal{N}(3, 2^2), \qquad \tau \sim \mathcal{N}^+(0, 1^2),$$

où $\mathcal{N}^+(0, 1^2)$ désigne une loi normale centrée en 0 et tronquée à $\mathbb{R}_+$.

Justification :

- μ est la moyenne de $z_i = \log \lambda_i$. Son support est donc $\mathbb{R}$.
- Une loi normale est adaptée à ce support.
- Le centre 3 donne $e^3 \simeq 20$, ordre de grandeur plausible pour une intensité annuelle.
- La variance 2^2 est large : l'intervalle a priori approximatif à 95% est $[-1, 7]$, soit $[0{,}37, 1096]$ pour λ_i.
- τ est un écart-type. Son support est $\mathbb{R}_+$.
- La loi $\mathcal{N}^+(0, 1^2)$ respecte cette contrainte et reste faiblement informative.
- Une valeur $\tau = 1$ correspond à un facteur $e^{\pm 1}$, donc environ $[0{,}37, 2{,}72]$ autour du niveau moyen.

III - Estimation

6. Algorithme de type Hamiltonian Monte-Carlo

a) Paramétrisation retenue

La loi cible est la loi a posteriori de

$$(\log \lambda_1, \ldots, \log \lambda_I, \mu, \tau^2) \mid y.$$

Pour travailler sur un espace non contraint, on pose

$$z_i = \log \lambda_i, \qquad s = \log \tau^2.$$

Le vecteur d'état est

$$x = (z_1, \ldots, z_I, \mu, s) \in \mathbb{R}^{I+2}.$$

Pour chaque année i, on note

$$S_i = \sum_{j=1}^{n_i} y_{ij}.$$

Le modèle s'écrit

$$y_{ij} \mid \lambda_i \sim \mathcal{P}(\lambda_i).$$

Comme $\lambda_i = e^{z_i}$, on utilise pour HMC

$$y_{ij} \mid z_i \sim \mathcal{P}(e^{z_i}), \qquad z_i \mid \mu, \tau^2 \sim \mathcal{N}(\mu, \tau^2).$$

b) Densité cible et gradient

Par la formule de Bayes, la loi a posteriori est proportionnelle à la vraisemblance multipliée par la loi a priori. Pour

$$x = (z_1, \dots, z_I, \mu, s),$$

on écrit

$$p(x \mid y) \propto L(y \mid x) c(x).$$

Ici, cela donne

$$p(x \mid y) \propto L(y \mid z)\, \pi(z \mid \mu, s)\, \pi(\mu)\, \pi(s).$$

Pour la vraisemblance, on a, pour chaque année i,

$$y_{ij} \mid z_i \sim \mathcal{P}(e^{z_i}).$$

Donc

$$L(y \mid z) = \prod_{i=1}^{I} \prod_{j=1}^{n_i} \frac{e^{-e^{z_i}} (e^{z_i})^{y_{ij}}}{y_{ij}!}.$$

En prenant le logarithme,

$$\log L(y \mid z) = \sum_{i=1}^{I} \sum_{j=1}^{n_i} \left(-e^{z_i} + y_{ij} z_i - \log(y_{ij}!) \right).$$

Comme $S_i = \sum_{j=1}^{n_i} y_{ij}$,

$$\log L(y \mid z) = \sum_{i=1}^{I} \left(S_i z_i - n_i e^{z_i} \right) \; + \; \text{cte.}$$

Pour le niveau hiérarchique,

$$z_i \mid \mu, \tau^2 \sim \mathcal{N}(\mu, \tau^2), \qquad \tau^2 = e^s.$$

Ainsi,

$$\pi(z \mid \mu, s) = \prod_{i=1}^{I} \frac{1}{\sqrt{2\pi e^s}} \exp\left(-\frac{(z_i - \mu)^2}{2e^s} \right).$$

Donc

$$\log \pi(z \mid \mu, s) = -\frac{1}{2} \sum_{i=1}^{I} \left(\frac{(z_i - \mu)^2}{e^s} + s \right) \; + \; \text{cte.}$$

Pour μ, on a

$$\mu \sim \mathcal{N}(3, 2^2),$$

donc

$$\log \pi(\mu) = -\frac{(\mu - 3)^2}{8} \; + \; \text{cte.}$$

Enfin, pour τ, on a choisi

$$\tau \sim \mathcal{N}^+(0, 1).$$

Sa densité est donc, à constante près,

$$\pi(\tau) \propto \exp\left(-\frac{\tau^2}{2} \right) \mathbf{1}_{\{\tau > 0\}}.$$

Nous travaillons avec la variable

$$s = \log \tau^2, \qquad \tau = e^{s/2}.$$

Le jacobien vaut

$$\left| \frac{d\tau}{ds} \right| = \frac{1}{2} e^{s/2}.$$

Donc

$$\pi(s) \propto \pi(\tau(s)) \left| \frac{d\tau}{ds} \right| \propto \exp\left(-\frac{e^s}{2} \right) e^{s/2}.$$

Par conséquent,

$$\log \pi(s) = \frac{s}{2} - \frac{e^s}{2} \; + \; \text{cte.}$$

La log-densité a posteriori, à constante additive près, est

$$\log p(x \mid y) = \sum_{i=1}^{I} \left(S_i z_i - n_i e^{z_i} \right) \; - \; \frac{1}{2} \sum_{i=1}^{I} \left(\frac{(z_i - \mu)^2}{e^s} + s \right) \; - \; \frac{(\mu - 3)^2}{8} \; + \; \frac{s}{2} \; - \; \frac{e^s}{2}.$$

Le gradient utilisé dans le code est

$$\frac{\partial \log p}{\partial z_i} = S_i - n_i e^{z_i} - \frac{z_i - \mu}{e^s},$$

$$\frac{\partial \log p}{\partial \mu} = \sum_{i=1}^{I} \frac{z_i - \mu}{e^s} - \frac{\mu - 3}{4},$$

$$\frac{\partial \log p}{\partial s} = \frac{1}{2} \sum_{i=1}^{I} \frac{(z_i - \mu)^2}{e^s} - \frac{I}{2} + \frac{1}{2} - \frac{e^s}{2}.$$

c) Algorithme HMC utilisé

On note f la densité cible :

$$f(x) \propto p(x \mid y).$$

On choisit une matrice de masse

$$M = I_{I+2}.$$

On note r le moment auxiliaire, pour ne pas le confondre avec la densité p. On prend

$$r \sim \mathcal{N}(0, M).$$

HMC est une méthode MCMC sur l'espace augmenté (x, r). L'Hamiltonien est

$$H(x, r) = -\log f(x) + \frac{1}{2} r^\top M^{-1} r.$$

L'algorithme utilise seulement $\log f$, son gradient et des rapports de densités.

À chaque itération, on génère $R_n \sim \mathcal{N}(0, M)$. À partir de X_{n-1}, on pose

$$x^{(0)} = X_{n-1}, \qquad r^{(0)} = R_n.$$

On effectue L pas de leapfrog :

$$r^{\left(\ell+\frac{1}{2}\right)} = r^{(\ell)} + \frac{\varepsilon}{2} \nabla \log f\left(x^{(\ell)}\right),$$

$$x^{(\ell+1)} = x^{(\ell)} + \varepsilon M^{-1} r^{\left(\ell+\frac{1}{2}\right)},$$

$$r^{(\ell+1)} = r^{\left(\ell+\frac{1}{2}\right)} + \frac{\varepsilon}{2} \nabla \log f\left(x^{(\ell+1)}\right), \qquad \ell = 0, \ldots, L-1.$$

À la fin, on pose

$$Y_n = x^{(L)}, \qquad \widetilde{R}_n = -r^{(L)}.$$

On accepte enfin Y_n avec la probabilité

$$\alpha(X_{n-1}, R_n, Y_n, \widetilde{R}_n) = \min\left(1, \exp\big(H(X_{n-1}, R_n) - H(Y_n, \widetilde{R}_n)\big)\right).$$

Si le candidat est rejeté, $X_n = X_{n-1}$.

d) Choix de ε et L

$$\varepsilon \in \{0{,}03,\ 0{,}05,\ 0{,}07,\ 0{,}10\}, \qquad L \in \{5,\ 10,\ 15\}.$$

Pour chaque couple (ε, L), une chaîne courte donne

$$\widehat{a}(\varepsilon, L) = \frac{1}{N_{\text{grid}} - 1} \sum_{n=2}^{N_{\text{grid}}} \mathbf{1}_{\{\text{acceptation à l'itération } n\}}.$$

On retient le couple qui minimise

$$\left|\widehat{a}(\varepsilon, L) - 0{,}8\right|.$$

Ici,

$$(\varepsilon, L) = (0{,}07, 10).$$

Son taux d'acceptation de calibration est 0,8106 :

$$|0{,}8106 - 0{,}8| = 0{,}0106,$$

e) Réalisations produites

La chaîne finale a longueur

$$N = 20\,000.$$

Les réalisations sont stockées dans `echantillons_hmc.csv`. La ligne n contient

$$(\mu^{(n)}, \log(\tau^2)^{(n)}, (\tau^2)^{(n)}).$$

La variable `accept` vaut

$$\texttt{accept}^{(n)} = \mathbf{1}_{\{X_n \neq X_{n-1}\}}.$$

7. Performances de l'algorithme et convergence

a) Réglage retenu

Réglage final :

$$N = 20\,000, \qquad \varepsilon = 0{,}07, \qquad L = 10.$$

Le taux d'acceptation empirique vaut

$$\widehat{a} = \frac{1}{N-1}\sum_{n=2}^{N} \mathbf{1}_{\{X_n \neq X_{n-1}\}} = 0{,}8262.$$

On retire

$$B = 4\,000$$

premières itérations. Il s'agit du burn-in. Cela représente

$$\frac{B}{N} = 0{,}2$$

de la chaîne. L'échantillon conservé contient donc

$$N - B = 16\,000$$

réalisations.

b) Traces et moyennes cumulées

La figure 3 montre les chaînes et les histogrammes post burn-in. La droite verticale marque la fin du burn-in. Les trajectoires ne montrent pas de dérive visible après cette étape.

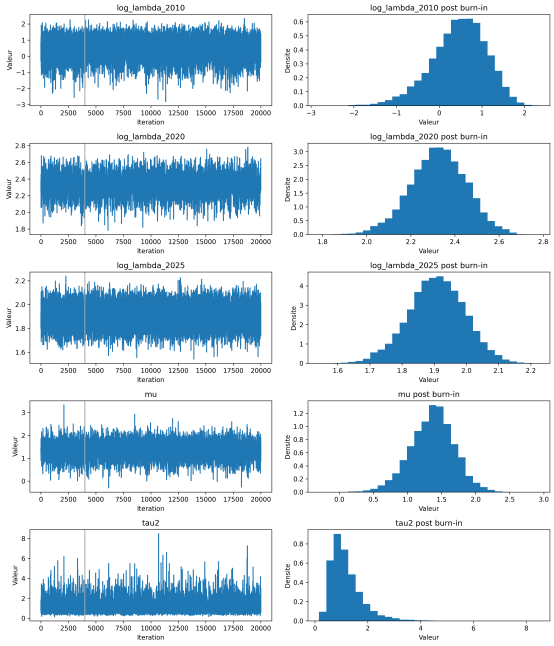


FIGURE 3 – Chaînes HMC et histogrammes post burn-in pour quelques composantes

Nous regardons aussi la moyenne cumulée

$$\overline{h}_n = \frac{1}{n}\sum_{t=1}^{n} h(X_t).$$

Si la chaîne explore bien sa loi stationnaire, ces moyennes doivent se stabiliser. C'est le cas pour μ, τ^2 et $\log \lambda_{2025}$. Les quantiles cumulés à 2,5% et 97,5% pour μ et τ^2 se stabilisent aussi après le burn-in.

c) Autocorrélation

Nous calculons l'autocorrélation empirique

$$\widehat{\rho}_k = \frac{\sum_{t=1}^{m-k}(x_t - \overline{x})(x_{t+k} - \overline{x})}{\sum_{t=1}^{m}(x_t - \overline{x})^2}, \qquad k \geq 1,$$

sur la partie post burn-in de longueur $m = 16\,000$.

Le tableau 1 résume quelques valeurs d'autocorrélation.

TABLE 1 – Résumé numérique des diagnostics HMC

Paramètre	$\widehat{\rho}_1$	$\widehat{\rho}_5$	$\widehat{\rho}_{10}$
$\log \lambda_{2010}$	0,5726	0,1187	0,0424
$\log \lambda_{2020}$	0,8067	0,3530	0,1165
$\log \lambda_{2025}$	-0,1241	-0,0069	-0,0125
μ	-0,1069	0,0275	0,0092
τ^2	0,3214	0,1057	0,0311

Pour μ, τ^2 et $\log \lambda_{2025}$, l'autocorrélation devient vite faible. Pour $\log \lambda_{2020}$, elle est plus forte aux petits retards. Elle décroît toutefois nettement entre les retards 1, 5 et 10.

d) Bilan

Le bilan est satisfaisant :
— taux d'acceptation : $\widehat{a} = 0{,}8262$;
— burn-in : $B = 4\,000$;
— échantillon conservé : $N - B = 16\,000$;
— traces stables après burn-in ;
— moyennes et quantiles cumulés stabilisés ;
— autocorrélations décroissantes.

8. Variabilité inter-année et intra-année

a) Quantités d'intérêt

Les estimations sont des résumés a posteriori :
— moyenne a posteriori ;
— médiane a posteriori ;
— quantiles a posteriori ;
— intervalles de crédibilité à 95%.
Dans le modèle,

$$Y_{ij} \mid \lambda_i \sim \mathcal{P}(\lambda_i), \qquad \log \lambda_i \mid \mu, \tau^2 \sim \mathcal{N}(\mu, \tau^2).$$

Les deux quantités principales sont :
— τ^2, qui mesure la dispersion des $z_i = \log \lambda_i$ entre années ;
— λ_i, qui contrôle la variabilité conditionnelle dans l'année i.
Pour une année i,

$$\mathbb{E}(Y_{ij} \mid \lambda_i) = \lambda_i, \qquad \mathrm{Var}(Y_{ij} \mid \lambda_i) = \lambda_i.$$

Les résumés a posteriori de λ_i donnent donc le niveau moyen et la variance conditionnelle dans l'année i.

b) Paramètres globaux

Le tableau 2 donne les résumés a posteriori des paramètres globaux.

TABLE 2 – Résumés a posteriori des paramètres globaux

Paramètre	Moyenne	Médiane	$q_{0.025}$	$q_{0.975}$
μ	1,3642	1,3800	0,6878	1,9810
τ	1,0575	1,0225	0,6517	1,6732
τ^2	1,1860	1,0455	0,4247	2,7996

L'estimateur de τ^2 est nettement positif. Son intervalle de crédibilité est

$$[0{,}4247,\ 2{,}7996].$$

L'intervalle ne contient pas 0. Cela indique une hétérogénéité entre années sur l'échelle de $\log \lambda_i$.

c) Variabilité entre années

La figure 4 donne, pour chaque année, la moyenne a posteriori de $\log \lambda_i$ puis celle de λ_i, avec un intervalle de crédibilité à 95%.

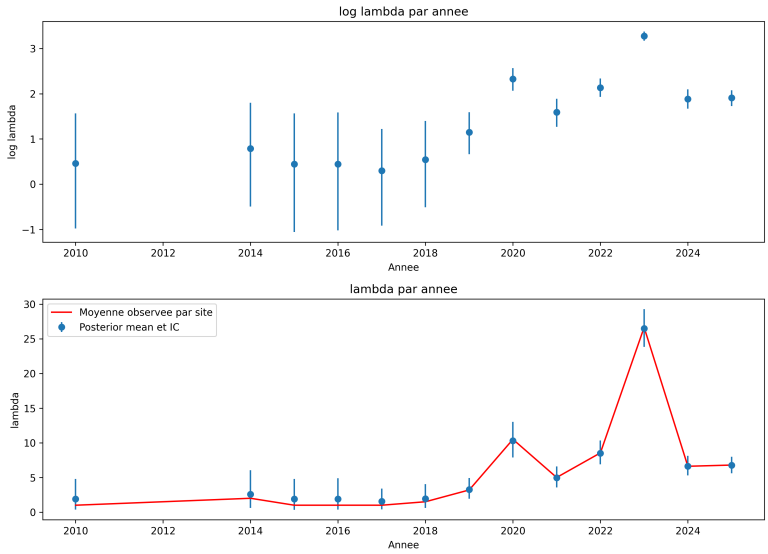


FIGURE 4 – Résumés a posteriori annuels pour $\log \lambda_i$ et λ_i

Sur l'échelle naturelle, les estimations a posteriori varient fortement selon l'année :

$$\widehat{\lambda}_{2020} = 10{,}3038, \qquad IC_{95\%}(\lambda_{2020}) = [7{,}8824,\ 13{,}0102],$$
$$\widehat{\lambda}_{2023} = 26{,}4946, \qquad IC_{95\%}(\lambda_{2023}) = [23{,}8465,\ 29{,}2734],$$
$$\widehat{\lambda}_{2025} = 6{,}7588, \qquad IC_{95\%}(\lambda_{2025}) = [5{,}6154,\ 7{,}9704].$$

L'année 2023 se distingue nettement. Les premières années ont des intensités plus faibles :

$$\widehat{\lambda}_{2010} = 1{,}9101, \qquad IC_{95\%}(\lambda_{2010}) = [0{,}3751,\ 4{,}7781].$$

d) Variabilité au sein des années

La loi conditionnelle est de Poisson. Donc

$$\mathrm{Var}(Y_{ij} \mid \lambda_i) = \lambda_i.$$

La variabilité intra-année estimée est donc égale à la moyenne conditionnelle estimée.
Exemples :

$$\widehat{\mathrm{Var}}(Y_{ij} \mid \text{année 2023}) \approx \widehat{\lambda}_{2023} = 26{,}4946.$$
$$\widehat{\mathrm{Var}}(Y_{ij} \mid \text{année 2020}) \approx \widehat{\lambda}_{2020} = 10{,}3038.$$
$$\widehat{\mathrm{Var}}(Y_{ij} \mid \text{année 2010}) \approx \widehat{\lambda}_{2010} = 1{,}9101.$$

9. Qualité prédictive du modèle

a) Loi prédictive a posteriori

Pour une observation future Y_{ij}^{rep},

$$p(y_{ij}^{\mathrm{rep}} \mid y) = \int p(y_{ij}^{\mathrm{rep}} \mid x)\, p(x \mid y)\, dx.$$

On l'approche avec les tirages HMC post burn-in. Si

$$x^{(m)} = (z_1^{(m)}, \ldots, z_I^{(m)}, \mu^{(m)}, s^{(m)})$$

est le m-ième tirage post burn-in, alors

$$Y_{ij}^{\mathrm{rep},(m)} \mid x^{(m)} \sim \mathcal{P}(e^{z_i^{(m)}}).$$

On utilise

$$\widehat{m}_{ij} = \frac{1}{M} \sum_{m=1}^{M} Y_{ij}^{\mathrm{rep},(m)}$$

comme prédiction ponctuelle. Les quantiles empiriques $q_{0.025}$ et $q_{0.975}$ donnent l'intervalle prédictif à 95%.

b) Critères globaux

Le tableau 3 résume la qualité prédictive sur les 84 observations. Les critères sont :
— RMSE ;
— MAE ;
— couverture prédictive ;
— log-densité prédictive moyenne.

TABLE 3 – Résumé global de la qualité prédictive

Critère	Valeur
N	20 000
B	4 000
n_{obs}	84
RMSE	26,3869
MAE	9,5248
Couverture obs. à 95%	0,5476
Log-densité prédictive moyenne	−9,0253
Couverture annuelle à 95%	1,0000

Les deux erreurs globales sont

$$\text{RMSE} = \sqrt{\frac{1}{84}\sum_{k=1}^{84}(y_k - \widehat{m}_k)^2} = 26{,}3869,$$

$$\text{MAE} = \frac{1}{84}\sum_{k=1}^{84}|y_k - \widehat{m}_k| = 9{,}5248.$$

La couverture à 95% au niveau des observations vaut

$$\widehat{c}_{\text{obs}} = \frac{46}{84} = 0{,}5476.$$

Elle est nettement inférieure à 0,95.

c) Résultats au niveau annuel

La figure 5 montre les totaux observés et les résumés prédictifs a posteriori.

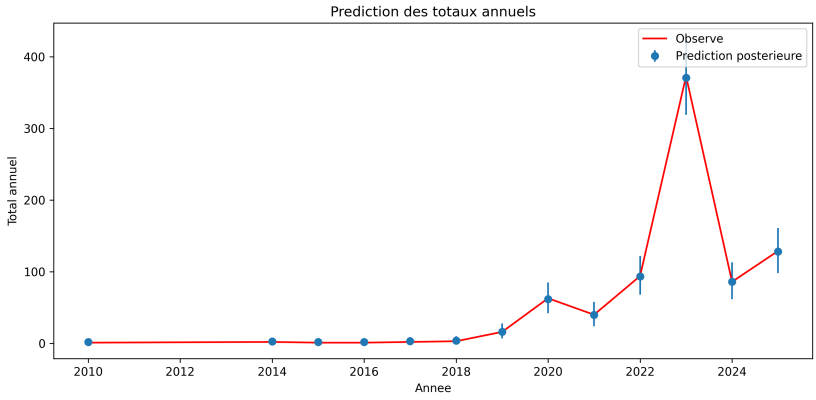


FIGURE 5 – Totaux observés et prédictifs par année

$$\widehat{c}_{\text{annee}} = \frac{13}{13} = 1.$$

Les 13 totaux observés sont dans leur intervalle prédictif à 95%.

Exemples :

$$y^{\text{tot}}_{2020} = 63, \quad \widehat{m}^{\text{tot}}_{2020} = 61{,}8093, \quad IC_{95\%} = [42,\ 85],$$
$$y^{\text{tot}}_{2023} = 373, \quad \widehat{m}^{\text{tot}}_{2023} = 370{,}9524, \quad IC_{95\%} = [319,\ 426],$$
$$y^{\text{tot}}_{2025} = 129, \quad \widehat{m}^{\text{tot}}_{2025} = 128{,}2886, \quad IC_{95\%} = [98,\ 161].$$

d) Bilan

— Prédiction annuelle : satisfaisante.
— Prédiction locale : plus limitée.

Sources

GBIF, *Global Biodiversity Information Facility*, `https://www.gbif.org/`.
Hamiltonian Monte Carlo, `https://en.wikipedia.org/wiki/Hamiltonian_Monte_Carlo`.
Root Mean Square Error (RMSE), `https://arize.com/blog-course/root-mean-square-error-rmse-what-you-need-to-know/`.
Mean Absolute Error, `https://en.wikipedia.org/wiki/Mean_absolute_error`.